

기준일 2026-09-17 | 의사결정·구현·검증 초안

Pally v2.0

현황 진단, 데이터 스키마와 5축 재설계 보고서

수집 가능한 근거로 사용자를 측정하고,
그 결과를 Pally의 점진적인 변화로 연결하는 설계

핵심 권고

Gemini는 유지한다. 독립 인간 평가를 확보하고, 발화·관계·학습 지원을 구분한 뒤, 분석 결과를 LLM과 TTS에 전달하는 적응 기능을 먼저 완성한다.

재편한 5개 제품 지표	측정 방식
공손성 / Spoken Politeness	현재 발화와 맥락의 인간 지각
음성 표현성 / Vocal Expressiveness	실제 음성과 운율의 인간 지각
관계 친숙도 / Familiarity	Pally 사용 이력과 시간 감쇠
밈·유행어 사용 / Meme & Slang Usage	문맥별 표현 사용 검수와 누적 집계
탐색 성향 / Exploratory Engagement	자발적 질문·이유 탐색·주제 확장

이 문서의 5축은 하나의 심리 성격 검사나 단일 ML 출력 벡터가 아니다. 네 개의 대화 행동 지표와 한 개의 관계 상태를 제품에서 함께 보여주는 구성이다.

상태: 설계 제안. 새 모델 학습·인간 채점·서비스 코드 변경을 수행한 결과가 아니다. 이전 v1.0 보고서의 Intimacy·Humor 해석은 이번 사용자 정의에 맞춰 수정한다.

DESIGN PROPOSAL v2.0

01 읽는 순서와 근거 범위

내용	페이지
문제 진단·현재 분석기와 LLM·corpus 적용 현황	03-07
5축 재편 이유·축별 Rubric·어휘 수집 대안	08-14
사용자 상태와 Pally 적응·영어 학습 지원	15
권장 스키마·필드 의미·JSONL 예시·런타임 상태	16-19
독립 채점·평가·데이터 분할·검증 실험	20-22
추가 개발·단계별 실행·모델링 담당 범위	23-24
선행연구 해석·출고 체크리스트·근거 목록	25-28

본문의 근거 표기

- [C] 코드·파일 확인: puter8/capstone, 커밋 1d2f93e2ef8fa14df18888792e872df0a378dd3b. 운영 서버의 환경변수·배포 버전은 확인하지 않았다.
- [U] 사용자 요구: 사용 이력 기반 Intimacy, 밈·유행어 사용 기반 Humor, 영어 수준에 따른 속도 조절, Pally가 사용자를 점진적으로 닮는 경험.
- [D] 데이터 제공자의 공개 문서·카드. 접근 가능하다는 안내와 실제 다운로드·학습 완료를 구분한다.
- [R] 기존에 제공된 선행연구 5편의 요약 자료. 이 보고서는 논문 5편의 원문을 모두 재검증한 문헌고찰이 아니다.
- [P] 새 설계 제안: 앵커, 수치 경계, 정책, 표본 수, 스키마. 실증 검증된 보편 기준으로 읽지 않는다.

DESIGN PROPOSAL v2.0

02 지금 해결해야 할 문제

문제	현재 근거와 영향	권장 해결
라벨 신뢰성	실제 발화에 rule/LLM 점수를 붙인 자료가 많음. 인간 발화라는 사실이 인간 라벨을 보장하지 않음.	독립 인간 anchor와 별도 final test 확보
측정 대상 혼합	기존 5축에 발화 표현·관계 상태·질문·유머가 섞임. 새 사용자 정의와 불일치.	4개 대화 지표 + 1개 관계 상태로 재편
입력 정보 부족	분석기는 현재 텍스트만 사용. 이전 발화·음성이 저장돼도 자동 활용되지 않음.	맥락·음성을 축별로 단계 도입
데이터 손실	원본의 맥락·출처가 통합·로딩 단계에서 일부 소실. 검수 후보는 라벨 미완성.	원본/채점 분리와 학습 export 검증
적응 연결 누락	주요 대화 경로에서 계산한 character를 Gemini/TTS에 전달하지 않음.	상태 → 응답 지침·음성 설정 연결
평가 재사용	gold-200을 이미 모델 진단에 사용함.	human dev로 관리하고 새 final 보존

현재 결과를 과장하지 않는다


공개 데이터만으로 얻을 수 있는 성능의 상한이 입증된 것은 아니다. teacher를 잘 재현하는 모델과 인간 지각에 맞는 모델은 별도로 평가해야 한다. 이번 보고서는 기존 성능 수치를 새 실험 결과처럼 재사용하지 않는다.

DESIGN PROPOSAL v2.0

03 현재 분석기와 Gemini의 역할

구성	입력	현재 동작
STT	사용자 음성	텍스트 변환. 주요 STT 설정은 자동 구두점 false.
분석기	현재 utterance	기본 rule. ml은 TF-IDF+kNN, hybrid는 평균. 맥락·운율 미사용.
누적·캐릭터	현재 점수와 이전 점수	이동평균 후 tone_casual / energy_level / humor_level 계산.
대화 Gemini	현재 텍스트·최근 10개 메시지·이름·영어 수준	답변 생성. 코드 실제 요청 모델은 gemini-2.5-flash-lite.
TTS	답변 텍스트	주요 음성 대화 경로는 기본 speaking_rate=1.0 호출.
연구용 teacher	학습·평가용 발화	LLM이 축별 weak label 생성. 대화 생성과 별도 역할.

현재 주요 경로



연결해야 할 부분

위 두 경로 사이에 적응 정책이 필요하다. 계산한 성향을 응답 지침으로 변환하고, 영어 수준·이해 상태로 음성 속도를 설정한다. LLM이 맥락상 말투를 따라 하는 현상은 관리되는 장기 적응의 구현 증거가 아니다.

DESIGN PROPOSAL v2.0

04 corpus는 현재 어디에 쓰이나

현재 corpus는 분석기 연구·검수 후보·평가에 적용된다. Gemini를 corpus로 파인튜닝하거나 매 응답에서 corpus를 검색하는 경로는 확인되지 않았다.

출처	통합 실험 3,137	정제 실험 2,940	human dev 200
seed·AI 보조 자료	338	338	-
NICT JLE	600	567	68
AMI	599	441	67
Taskmaster	500	494	65
CHiME	600	600	-
HCRC MapTask	500	500	-

- 기본 rule은 이 파일을 학습하지 않는다. ml 선택 시에도 별도 PALLY_AXIS_DATASET 설정이 없으면 기본 338행 파일을 읽는다.
- 기본 338행은 source가 gemini_assisted 110, gpt_assisted 99, claude_assisted 99, 미기재 30이다. 공개 corpus 학습을 기본 배포 상태로 오인하지 않는다.
- 새 후보 1,200행은 NICT·AMI·Taskmaster 각 400행이며 axes가 모두 null이다. 검수 후보 확보와 학습 라벨 완성은 다르다.
- 원본·새 후보에 previous/next가 있으나 통합 실험 3,137행에는 없다. 2,940행 파일은 utterance/source/axes/style만 보존한다.

HCRC 사용 상태

연구 파일에는 들어 있지만 저장소 manifest는 라이선스 상충으로 확인 보류를 표시한다. 기존 실험 결과의 포함 여부를 기록하고, 제품용 export에서는 확인 전 제외한다. 새 승인을 받은 것으로 해석하지 않는다.

DESIGN PROPOSAL v2.0

05 이미 추출한 corpus의 적합한 역할

자료	확보 상태	좋은 사용처	한계
NICT JLE	추출 텍스트 139,772행	학습자 오류·머뭇거림·짧은 발화에서도 공손성/탐색 판단 유지	면접 과제와 L2 수준의 영향. 자유 대화 성격으로 일반화 금지
AMI	추출 텍스트 98,475행	설명·의견·질문·동의/반대의 맥락과 화자 역할	회의의 역할·주제가 발화 행동을 제약
Taskmaster WOZ	사용자 발화 60,347행	요청·확인·정보 수정·문제 해결의 대화 행위	과제 수행 행동을 호기심/성격으로 바로 환산 금지
CHiME	추출 텍스트 87,539행	짧은 반응·겉침 발화·잡음 조건. 음성 연결 후 표현성 평가	현재 전사 추출과 오디오 학습 연결은 별개
HCRC	추출·실험 포함	설명·확인·수정 대화의 연구 사례	현재 제품용 사용은 보류

모든 자료에 공통 적용할 선정 규칙

- noise-only는 제외한다. “yeah”, “uh-huh” 같은 backchannel은 무조건 제거하지 않고 별도 stratum으로 남긴다.
- 실제 즉흥 발화·낭독·사람이 작성한 텍스트·합성 문장을 구분한다. 전사 문장이 있다는 사실만으로 human_spoken=true를 부여하지 않는다.
- STT 원문과 사람이 고친 전사를 분리한다. 서비스와 같은 구두점·오류 조건에서도 평가한다.
- corpus 이름으로 특정 축의 점수를 자동 결정하지 않는다. 상황별 사례 확보에 사용하고 라벨은 새 기준으로 검수한다.

DESIGN PROPOSAL v2.0

06 추가 확보 가능한 자료와 역할

자료	확인된 제공 정보	권장 활용과 접근 조건
otoSpeech	280h 두 화자 분리 음성. 일부 참여자 설문에 playfulness/initiative/comfort.	표현성·자연 반응 후보. raw 280h는 전사 필드가 없는 구성. CC BY 4.0 표시, 파일 접근 동의 필요. [D1]
otoSpeech Task	약 20h 과제 수행 대화·과제 정보.	설명·확인·협업 사례. 학습 지원 필요 정답으로 직접 쓰지 않음. [D2]
ICSI	실제 회의 75개·약 72h와 인간 전사. 대화행위 연구 자료.	맥락과 공손성/탐색 후보. 사용할 원본·주석 버전의 접근/권한은 별도 확인. [D3]
DiPCo	4인 대화 10세션, 근거리/원거리 음성·인간 전사.	마이크·잡음에 따른 측정 안정성. 배포 문서는 CDLA-Permissive 표기. [D4]
MSP-Conversation	310대화·77h26m, 6명 이상이 연속 arousal/valence/dominance 평가.	일시적 음성 상태 연구. 표현성 정답과 동일하지 않음. 기관 서명 Academic License. [D5]
Open Yap	친구·가족 등의 분리 채널 음성. 전사는 기계 생성·인간 미검수.	일상 표현·말차례. 공개 샘플 8.9h는 CC BY 4.0, 전체 1,000h는 별도 신청·이용 계약. [D6]

현재 도입 완료 자료가 아니다

위 자료는 확인한 현행 학습 파일에 포함되지 않는다. 우선 작은 표본의 다운로드·정합성·권한을 확인한 뒤 라벨링한다. 세션 설문을 발화마다 복사하거나, 친구 관계를 Pally 친숙도 정답으로 환산하지 않는다.

DESIGN PROPOSAL v2.0

07 5축 재편: 무엇을 남기고 바꾸나

기존	새 표시명 / 내부 키	변경 이유·확보할 근거
Formality	공손성 spoken_politeness	구어적 요청·거절의 배려 표현에 한정. 텍스트·맥락과 인간 채점 확보 가능.
Energy	음성 표현성 vocal_expressiveness	말속도와 성격의 혼동을 줄이고 억양·강세 변화에 초점. 음성 없으면 판단 보류.
Intimacy	관계 친숙도 familiarity	사용 빈도·최근성이라는 제품 정의를 반영. 발화 회귀 대신 이벤트 이력으로 계산.
Humor	밈·유행어 사용 meme_slang_usage	웃김의 강도 대신 실제 어휘 사용으로 좁힘. 표현별 검수와 버전 있는 목록으로 시작 가능.
Curiosity	탐색 성향 exploratory_engagement	질문 기호 대신 자발적 이유 탐색·후속 확장 관찰. 이전 맥락과 기획 여부 필요.

4개 대화 지표 + 1개 관계 상태

제품은 다섯 항목을 유지할 수 있지만 하나의 5출력 학습기로 모두 예측할 필요는 없다. familiarity는 별도 계산기로 관리한다. 다섯 값을 평균해 “좋은 성격 점수”를 만들지 않는다.

- 표시값은 0~100으로 통일할 수 있으나 측정 단위·관찰 기간·신뢰도를 함께 표시한다. 80점이 축마다 동일한 통계적 의미를 갖지는 않는다.
- 음성이 없으면 표현성을 텍스트 점수로 채워 넣지 않는다. 표시를 보류하거나 별도 text_perceived 지표로 명시한다.
- 이 설계는 관찰 가능한 대화 성향이다. Big Five·MBTI 같은 심리 성격을 검증 없이 추정한다고 주장하지 않는다.

08 Rubric 1 : 공손성

정의·단위·입력

상대의 부담과 선택을 고려해 요청·거절·반대를 표현하는 정도. target utterance와 이전 맥락을 기본 입력으로 한다. 필요한 경우 실제 음성을 보조로 제공하며 조건을 기록한다.

점수	앵커
0	관찰 가능한 요청·거절에서 완화나 배려 표현이 거의 없이 매우 직접적이다.
25	대체로 직접적이며 간단한 예의 표현만 있다.
50	일상적인 수준으로 공손하게 요청·거절한다.
75	상대의 부담·선택을 고려한 완곡함이 뚜렷하다.
100	관련 발화에서 매우 강한 배려·존중·신중한 완화가 나타난다.

경계 사례와 제외 조건

- “Coffee, please.”는 짧아도 공손할 수 있다. 문장 길이·문법 정확성·희귀 단어를 점수로 대체하지 않는다.
- “It’s blue.”처럼 공손성 판단 기회가 거의 없는 진술은 극단값을 강제하지 않는다. 정보 부족은 null + not_observable.
- 직접적인 말이 반드시 무례한 것은 아니다. 공격성은 별도 사건 기록으로 다루고 낮은 공손성과 동일시하지 않는다.
- 역할극의 손님 역할·면접 지시 때문에 나온 공손함은 spontaneous 성향과 구분한다.

자료 전략: NICT·Taskmaster·AMI/ICSI에서 요청·거절·반대 사례를 선정하고 새 독립 인간 라벨을 만든다. 기존 5축 점수는 정의가 같고 채점 조건이 검증된 경우에만 재사용을 검토한다.

출력 연결

공손성이 높아지면 Pally의 요청·제안을 더 완곡하게 만든다. 유행어 사용이나 관계 친숙도는 자동으로 낮추지 않는다.

VOCAL EXPRESSIVENESS | 앵커는 검증 전 제안 (P)

09 Rubric 2: 음성 표현성

정의·단위·입력

발화에 들리는 억양·강세·강조 변화의 표현 정도. target audio와 필요한 맥락 음성을 사용한다. 느린 말속도·낮은 영어 수준을 낮은 표현성으로 처리하지 않는다.

점수	앵커
0	관찰 가능한 발화에서 억양·강조 변화가 매우 절제돼 있다.
25	표현적 변화가 작다.
50	보통 수준의 억양·강세 변화가 들린다.
75	강조와 억양 변화가 풍부하다.
100	충분한 발화 구간에서 매우 강한 표현적 변화가 지속된다.

기술적 관측과 인간 채점을 구분한다

- pitch 범위·강도 변화·강세는 보조 특징이다. Hz·dB가 곧 정답 점수는 아니다. 화자 기본 음역·마이크 거리·이득을 고려한다.
- 음성이 없거나 짧고 잡음이 심하면 null과 사유를 저장한다. 웃음은 유용한 사건 정보지만 웃음 하나로 100점을 부여하지 않는다.
- 분노·불안도 표현이 강할 수 있다. 긍정 감정, arousal, 외향성과 동일한 축으로 취급하지 않는다.
- 음성 표현성은 음성 조건끼리 평가한다. 텍스트 느낌표로 만든 구 Energy 점수와 같은 타깃으로 혼합하지 않는다.

자료 전략: otoSpeech/Open Yap에서 소량 음성 후보를 얻고 Pally 기준으로 채점한다. CHiME/DiPCo는 잡음·거리 안정성, MSP는 관련 감정 특징의 보조 연구에 사용한다. (D1, D4-D6)

출력 연결

사용 중인 TTS가 지원하고 검증한 범위에서 강조·표현을 조절한다. 속도는 영어 수준·듣기 지원 설정에서 결정한다. 음성 제어 가능 여부를 실제 API로 검증하기 전 구현 완료로 간주하지 않는다.

FAMILIARITY | 발화 라벨이 아닌 제품 상태 (U, P)

10 Rubric 3: 관계 친숙도

정의·단위·입력

사용자와 Pally 사이에 축적된 유효한 사용 이력과 최근성. 사용자 단위·시점별 값이다. 대화 속 친근한 단어, 사람의 애정·신뢰를 대신 측정하는 값이 아니다.

표시 앵커	제품상 의미
0	유효한 대화 이력이 거의 없다.
25	초기 대화 경험이 쌓이기 시작했다.
50	여러 번의 사용으로 공유한 대화 이력이 쌓였다.
75	반복적이고 최근까지 이어진 사용 관계다.
100	정한 상한 기준에서 높은 활동성과 최근성을 유지한다.

계산기의 제안 구조

$$F(t) = \text{clip}(F(\text{previous}) * 2^{(-\text{inactive_days} / H)} + \text{session_gain}, 0, 100)$$

H는 비활성 감쇠의 반감기, session_gain은 유효한 대화량에 따른 증가분이다. 일별 증가 상한을 두고 중복·재전송 이벤트는 한 번만 집계한다. H와 증가량은 아직 미확정이며 사용자 경험 실험으로 정한다.

- 수집 필드: user_id, session_id, event_id, event_time, active_days, valid_turn_count, last_active_at. 단순 앱 열기와 실제 대화를 구분한다.
- 감쇠는 무활동 기간 때문에 발생한다. 같은 시간 간격을 여러 번 중복 차감하지 않도록 계산 기준 시각을 저장한다.
- 미사용을 성격 변화로 학습하지 않는다. 점수 감소가 기억 삭제·차가운 응답·불이익을 자동 유발하지 않도록 정책을 분리한다.

평가 방법

사람 둘의 ICC를 계산할 대상이 아니다. 동일 이벤트 재처리·시간 경과·경계값에 대한 계산 검증과, 관계 표현이 자연스러운지 사용자 평가를 수행한다. 공개 corpus로 이 점수의 정답을 만들 수 없다.

MEME & SLANG USAGE | 웃김의 강도와 구분 (U, P)

11 Rubric 4: 밈·유행어 사용

정의·단위·입력

밈·유행어를 자신의 대화 표현으로 자발적으로 사용하는 정도. 먼저 표현 구간을 판정하고, 여러 발화 구간에서 사용률을 집계한다. 농담의 재미나 전반적인 언어 능력을 측정하지 않는다.

표현별 분류	판정 예시와 집계
자발적 사용	문맥에서 해당 의미로 직접 사용. 분자에 포함.
뜻 질문	“What does rizz mean?": 학습 질문. 사용률 분자에서 제외.
인용·따라 읽기·연습	다른 사람의 표현 인용, Pally가 지시한 반복. 별도 기록.
모호함·STT 의심	일반 단어 의미와 슬랭 의미를 구분하기 어렵거나 음성 오류. 확정 사용으로 세지 않음.

파일럿용 산출안: $r = \text{자발적 사용이 확인된 턴 수} / \text{판정 가능한 자유 발화 턴 수}$. 한 턴에서 같은 표현을 반복해도 1회로 센다. 최소 20개 판정 가능 턴을 임시 기준으로 두되 검증 후 조정한다.

앵커	사용률 구간의 초기 제안
0	$r = 0$. 충분한 관찰이 있을 때만 부여.
25	$0 < r \leq 0.10$
50	$0.10 < r \leq 0.30$
75	$0.30 < r \leq 0.60$
100	$0.60 < r \leq 1.00$

이 경계는 검증된 인구 기준이 아닌 초기 제품 설정이다. 원래 비율·분모·관찰 기간·표현 종류 수를 함께 보존한다. 최신 유행 여부가 확인되지 않은 표현을 “현재 트렌드”로 표시하지 않는다.

EXPLORATORY ENGAGEMENT | 앵커는 검증 전 제안 (P)

12 Rubric 5: 탐색 성향

정의·단위·입력

기회가 있을 때 이유·경험·관점에 대해 자발적으로 질문하고 대화를 확장하는 행동. 이전 맥락+현재 발화로 사건을 표시하고, 여러 기회에 걸친 행동을 구간 단위로 평가한다.

점수	앵커
0	탐색 기회가 충분히 있었으나 필요한 답변에서 마무리한다.
25	간단한 추가 정보 확인을 드물게 한다.
50	이유·경험에 대한 자발적 후속 질문이 관찰된다.
75	앞선 답을 받아 여러 단계로 질문하거나 주제를 확장한다.
100	여러 기회에서 관점 비교·가설·깊은 이유 탐색을 지속한다.

먼저 행동과 기회를 기록한다

- event_type 예: follow_up, why_question, perspective_comparison, topic_extension, clarification_for_hearing, prompted_question.
- “Could you repeat that?”은 우선 듣기·이해 지원 요청이다. 호기심 점수를 자동 가산하지 않는다.
- Pally가 질문을 연속으로 던져 사용자가 답하기만 한 구간은 자발적 탐색 기회가 부족할 수 있다. 기회가 없으면 null로 둔다.
- 문법이 단순한 “Why?”도 맥락상 깊은 탐색일 수 있다. 유창성·질문 길이를 성향으로 대체하지 않는다.

자료 전략: AMI/ICSI-Taskmaster-otoSpeech Task는 대화행위 후보를 제공한다. 자발적 탐색이라는 새 기준은 별도로 채점한다. NICT·실제 Pally 대화로 학습자 조건을 보완한다.

출력 연결

탐색 성향이 높으면 관련 이유·관점·후속 주제를 더 제공한다. 사용자가 질문을 많이 한다는 이유로 Pally도 질문만 많이 하게 하지 않는다. 역할에 맞는 응답을 설계한다.

DESIGN PROPOSAL v2.0

13 Reddit 없이 어휘 사용을 다루는 법

현재 어휘 모듈은 고정 목록의 표현을 찾는 기능에 가깝다. Reddit에서 새로운 유행어를 자동 발견·학습하고 서비스에 주입하는 연결이 완성된 상태로 보지 않는다.



작업	권장 방식
초기 목록	출처와 사용 조건을 확인할 수 있는 소규모 수동 목록으로 시작. 의미·예문·일반 의미와의 차이를 검수.
후보 발견	동의한 Pally 사용자 발화와 사용 가능한 corpus에서 후보를 추출. 자동 후보는 승인 전 학습·응답 목록에 넣지 않음.
최신성 관리	first_seen, last_verified_at, region, meaning, evidence_refs, vocabulary_version 기록. 오래된 표현도 삭제보다 상태 관리.
학습과 검색 구분	뜻·예문을 응답 시 참고하는 목록과, 사용 여부를 분류하는 모델을 분리. 목록 추가 때마다 LLM 파인튜닝할 필요 없음.
검증	일반 의미·뜻 질문·인용·연습을 포함한 독립 예제로 정확도 확인. 단순 키워드 매칭과 문맥 판정을 비교.

공개 corpus의 한계

자연 대화 corpus가 최신 밈을 충분히 포함한다고 보장할 수 없다. 유행어 측은 전체 corpus를 더 모으는 것보다 표현별 근거·문맥 검수와 Pally 자체 관찰이 중요하다.

- 유행어를 쓰지 않는 사용자에게 0은 정상적인 스타일이다. 높은 점수가 더 좋은 영어라는 의미가 아니다.
- 발견용으로 의도적으로 모은 고유행어 표본과 실제 사용률 평가 표본을 분리한다. 선정 편향이 있는 표본으로 이용자 평균을 계산하지 않는다.

DESIGN PROPOSAL v2.0

14 측정값이 Pally 변화로 이어지는 구조



상태	변화 속도	반영 대상
현재 대화 상태	빠름	이번 응답의 설명·배려·표현 정도
장기 대화 성향	여러 세션에서 천천히	Pally의 기본 말투·어휘·반응 성향
관계 친숙도	사용 이력·비활성 시간	재방문 인사·공유 경험 언급
영어 수준·지원 필요	수준 평가·실제 요청	어휘·문장 복잡도·속도·쉽·교정

초기 정책의 원칙

- 명시적 선호를 추정정보다 우선한다. 사용자가 말수가 적어도 질문 많은 Pally를 원할 수 있다.
- 한 번의 긴 역할극이나 일시적 기분이 장기 성향을 지배하지 않게 한다. 최소 근거량·신뢰도·변화 상한은 파 일럿으로 정한다.
- Pally가 유행어를 먼저 제시해 사용자가 따라 한 경우를 기록한다. 시스템이 만든 반응을 사용자 본래 성향으로 되먹임하지 않는다.
- 같은 A2라도 공손하고 차분한 Pally와 캐주얼하고 활기찬 Pally가 가능하다. 둘 다 쉬운 영어와 적절한 속도를 유지할 수 있다.

STT의 역할

STT는 사용자의 실제 말을 충실하게 전사한다. 친숙도·캐릭터 때문에 전사를 임의로 바꾸지 않는다. 어휘 힌트를 쓰더라도 오인식 증가 여부를 별도 평가한다.

DESIGN PROPOSAL v2.0

15 권장 스키마: 원본과 채점 분리

저장 단위	대표 필드	목적
samples	sample_id, source_corpus, source_version, conversation_id, session_id, speaker_id, learner_id, turn_id, segment_id	발화의 동일성·원본 추적
입력 내용	target_text_raw, target_text, text_variant, transcript_origin, transcript_verified, previous_turn, next_turn, context_turn_ids	원문·전사·실제 맥락 구분
음성·기원	audio_ref, start_ms, end_ms, channel, human_spoken, collection_mode, utterance_origin, elicitation_mode	음성 구간과 즉흥/낭독/합성 구분
분할·선택	split, split_group_id, sampling_stratum, selection_reason, inclusion_status, exclusion_reason	누출 방지·표본 편향 추적
권한	license_name, license_url, license_status, license_checked_at, allowed_use	사용 가능한 export만 생성
공통 버전	schema_version, created_at, source_record_id	변환과 재현성

보관 필드와 예측 특징은 다르다

source_corpus·license·annotator_id는 주로 관리 정보다. 분석 모델에 전부 넣지 않는다. corpus를 라벨의 지름길로 학습하거나 검수자에게 출처가 노출되는 것을 방지한다.

JSONL은 중첩 구조로 저장할 수 있다. CSV는 samples·annotations·observation_windows를 ID로 연결한다. 음성 파일 자체는 별도 저장하고 audio_ref는 관리되는 참조를 가리키게 한다.

DESIGN PROPOSAL v2.0

16 채점·관찰 구간·외부 라벨 스키마

단위	권장 필드	규칙
annotations	annotation_id, subject_id, measurement_scope, axis, score, label_origin, annotator_id	subject_id는 scope에 따라 sample 또는 window를 참조.
채점 조건	annotation_view, modality, evidence_turn_ids, evidence_spans, missing_reason, confidence	실제로 본/들은 정보 기록. 미래 발화 노출 구분.
작업 이력	rubric_version, order_seed, independence_verified, status, revision_of, change_reason, teacher_ref, created_at	독립 제출과 수정 이력 보존. teacher 모델·prompt 버전 기록.
집계 결과	aggregate_method, member_annotation_ids, score, disagreement, n_raters	원점수와 평균·합의 점수를 별도로 보존.
observation_windows	window_id, user_id, session_ids, turn_ids, window_start, window_end, n_eligible, n_observed	뮌·탐색처럼 여러 발화에 걸친 관찰 단위.
외부 원본 라벨	external_labels: name, value, scale, scope, source_ref	MSP 감정·oto 설문 등은 원래 단위·척도로 유지.

- score는 실수 0~100 또는 null. 결측을 0.50으로 바꾸지 않는다. 평균의 소수점을 학습 전에 임의 절삭하지 않는다.
- 11개 기존 style category는 발화 유형 taxonomy로 별도 보존한다. 성향 점수·제품 5축과 동일한 분류가 아니다.
- 새 필드를 넣는 것만으로 새 평가 축이 생기지 않는다. 입력·관리·정답·상태 중 용도를 데이터 사전에 명시한다.

SCHEMA EXAMPLE | 전부 설명용 가상 값, 학습·평가 제외

17 JSONL 예시: 하나의 발화와 두 조건

아래는 필드를 줄인 예시다. 합성 예시임을 명시하고, 음성이 없으면 음성 표현성을 결측으로 둔다. 관계 친숙도는 발화 labels에 넣지 않는다.

```
{
  "schema_version": "pally-data-2.0",
  "sample_id": "DEMO-001",
  "source_corpus": "illustrative_only",
  "conversation_id": "DEMO-C1",
  "speaker_id": "DEMO-U1",
  "turn_id": "t2",
  "target_text_raw": "Could you explain why that happens?",
  "target_text": "Could you explain why that happens?",
  "previous_turn": {
    "turn_id": "t1",
    "speaker_id": "DEMO-P",
    "text": "It changes in cold weather."
  },
  "next_turn": null,
  "audio_ref": null,
  "human_spoken": false,
  "utterance_origin": "synthetic_text",
  "transcript_origin": "not_applicable",
  "split": "excluded",
  "inclusion_status": "excluded",
  "exclusion_reason": "documentation_example",
  "labels": [
    {
      "annotation_id": "DEMO-A1",
      "subject_id": "DEMO-001",
      "measurement_scope": "utterance",
      "axis": "spoken_politeness",
      "score": 75.0,
      "label_origin": "illustrative_only",
      "rubric_version": "pally-rubric-2.0-draft",
      "annotation_view": "previous_target",
      "modality": "text_context"
    },
    {
      "annotation_id": "DEMO-A2",
      "subject_id": "DEMO-001",
      "measurement_scope": "utterance",
      "axis": "vocal_expressiveness",
      "score": null,
      "label_origin": "illustrative_only",
      "modality": "audio_context",
      "missing_reason": "no_audio"
    }
  ]
}
```

CSV에서 분리

samples.csv 한 행은 한 발화, annotations.csv 한 행은 한 채점 × 한 축 × 한 조건이다. 원본 sample_id 연결은 유지하고 검수 화면에는 불필요한 출처를 숨긴다.

DESIGN PROPOSAL v2.0

18 사용자 상태·실제 적응 로그

저장 단위	필드 예시	필요한 이유
user_style_state	user_id, observed_at, baseline_scores, current_scores, evidence_window_ids, n_observations, confidence, state_version	장기 성향과 현재 상태를 구분
relationship_state	user_id, familiarity_score, last_active_at, last_updated_at, activity_summary, decay_policy_version	사용·시간 기반 친숙도 재현
learning_profile	user_id, level, level_source, assessed_at, listening_support, correction_preference, pace_preference	성격과 영어 학습 지원 분리
lexical_events	sample_id, span, term_id, usage_type, vocabulary_version, evidence, review_status	임 사용률의 근거·분모 확인
adaptation_log	turn_id, measurement_version, state_snapshot_id, policy_version, prompt_version, model_id, response_controls, tts_controls	측정 오류와 응답 정책 오류 구분

현재 필드에서 옮기는 방법

기존	v2.0 처리
utterance / source	target_text + 출처 분류로 변환. corpus명과 라벨 생성자를 분리.
axes	구버전 annotations로 보존. 새 축 정의로 이름만 바뀌 재사용하지 않음.
previous_turn 문자열	화자·turn ID를 가진 객체로 변환. 연결이 불명확하면 표시.
labeler / reviewer_id	annotator 식별과 label_origin을 분리. 독립성은 증거로 검증.

개인 식별 연결표와 원음의 접근 범위를 구분한다. 재현에 필요한 ID·버전은 남기되 전체 원음·개인정보를 모든 학습 export에 복제하지 않는다.

DESIGN PROPOSAL v2.0

19 인간 라벨과 품질 관리

출처 수준	용도·해석
독립 인간 gold	기준·순서·제출 독립성이 확인된 인간 채점. 최우선 평가 근거.
검증된 인간 검수	AI 초안을 수정한 경우 등. 원래 독립 채점과 구분.
LLM teacher weak	학습 규모 확장·후보 선별에 활용. human gold 대체 불가.
rule pseudo-label	기준선·초기 실험용. rule의 편향을 재현할 수 있음.
합성 발화	입력의 생성 방식. 라벨 출처 등급과 별도 차원으로 기록.

합성 문장도 사람이 평가할 수 있고, 인간이 말한 문장도 AI가 평가할 수 있다. 따라서 human_spoken과 label_origin을 한 등급으로 합치지 않는다.

- 새 anchor 80~120개는 전부 독립 이중 채점. 일반 확장 세트는 최소 20% 이중 채점을 출발점으로 삼는다.
- 출처·AI/rule 점수와 다른 검수자의 결과를 숨긴다. 순서를 독립적으로 섞고 제출 후 수정 사유를 남긴다.
- 원 채점 보존 → 축별 일치도 계산 → 불일치 원인 검토 → 필요시 기준 수정·재채점 순으로 진행한다.
- 비정상적으로 높은 완전 일치는 공유·복사·UI·export·중복 입력 등 다양한 원인을 점검한다. 독립성 확인 전 보류하며 특정인의 부정행위를 단정하지 않는다.

라벨 대상별 작업을 나눈다

공손성·표현성·탐색은 지각/행동 평가, 믿음 표현 분류와 집계, 친숙도는 계산 규칙 검증이다. 모든 필드에 사람의 0~100 채점을 요구하지 않는다.

AI 문장 제작 -> 사람이 평가 -> 평가 결과 블라인드 하에 교차검증

20 평가 지표와 split 원칙

지표	쉬운 의미	주의점
ICC	같은 대상을 여러 사람이 얼마나 비슷한 점수로 평가하는가	절대 일치/일관성, 단일/평균 평가자 유형과 신뢰구간 명시
Spearman	높고 낮은 순서가 비슷한가	전부 20점 높아도 순서가 같으면 높을 수 있음
MAE	평균적으로 몇 점 차이 나는가	0~100 척도·채점 조건·축을 맞춰 비교
Exact agreement	완전히 같은 값의 비율	높다고 자동 신뢰/부정행위 판정하지 않음
정밀도·재현율	밈 사용·행동 사건을 얼마나 정확히 찾고 놓치지 않는가	최소한 positive와 문맥별 혼동을 함께 보고

분할 원칙

- 같은 conversation/session과 연결된 speaker/learner가 train과 test에 동시에 들어가지 않게 그룹을 먼저 만든다. 여러 대화에 걸친 같은 화자 연결도 처리한다.
- 원음·재전사·부분 발화·문맥 창·증강 버전은 원본 그룹을 공유한다. 파일명만 다르다고 독립 표본이 아니다.
- gold-200은 이미 진단에 사용했으므로 human dev다. v2.0 정의와 조건이 달라지면 그대로 새 정답으로 사용할 수 없다.
- 별도의 final 100~200개를 이후 확보하고 정의·모델·정책을 고정한 뒤 평가한다. 화자 수와 신뢰구간도 보고한다.

성능 주장 범위

사람과 모델의 평균 점수가 가까워도 관계 친숙도·장기 성격·학습효과까지 검증된 것은 아니다. 같은 사람에게서 나온 많은 발화를 독립 사람 수처럼 계산하지 않는다.

DESIGN PROPOSAL v2.0

21 무엇을 비교해야 개선을 알 수 있나

실험	비교 조건	확인할 결과
텍스트·맥락	target-only vs previous+target	공손성·탐색의 인간 기준 오차가 줄어드는가
음성 가치	텍스트 기반 대조군 vs 음성 포함	동일한 audio gold에서 표현성 예측이 개선되는가
ميم 판정	키워드 매칭 vs 문맥별 분류	뜻 질문·인용의 오탐을 줄이는가
녹음 안정성	근거리/원거리·잡음·STT 조건	같은 발화의 측정이 불필요하게 변하지 않는가
캐릭터 제어	분석기 대신 지정한 가상 상태 주입	Gemini/TTS가 의도한 방향으로 반응하는가
실제 적응	고정 캐릭터 vs 점진적 반영	지각된 유사성·편안함·학습 수행의 차이

- 음성 모델과 텍스트 모델을 비교할 때 목표 라벨을 동일하게 둔다. 별도로 text-perceived와 spoken 라벨의 차이를 분석한다.
- 적응 실험에서는 영어 난이도·속도 조건을 맞춘다. 순서 효과·사용자별 차이를 고려하고 단기 선호와 학습 성과를 분리한다.
- 낮은 점수부터 높은 점수까지 같은 내용에 대해 응답이 의도대로 변하는지 검증한다. 수치만 API에 전달했다고 제어가 구현된 것은 아니다.
- 작은 anchor는 기준을 보정하기 위한 출발점이다. 100~200 final만으로 모든 영어 수준·녹음 조건에 대한 정밀한 하위집단 결론을 보장하지 않는다.

DESIGN PROPOSAL v2.0

22 추가 개발과 우선순위

순서	개발 범위	완료 조건
1	정의·스키마 확정	새 카·관찰 단위·결측·버전·구축 대상 corpus를 명시
2	원본/채점 변환·export	문맥·출처가 보존되고 제품용 제외 자료가 빠짐. train/dev 필터를 명시
3	검수 도구 보강	blind·독립 제출·순서·음성 재생·수정 이력 확인
4	anchor와 간단한 분석기	축별 일치도 확인 후 rule·ML·LLM 대조. 정의가 불명확하면 모델 확대 보류
5	상태·진속도 계산기	현재/장기 분리, 이벤트 중복·감쇠·명시적 선호 처리
6	Gemini·TTS 연결	적응 지침·속도·실제 적용값 기록. 지정 상태로 제어 검증
7	맥락·음성 모델 확장	필요한 축부터 도입. 부분 라벨·float·결측과 불확실성 처리
8	최종 평가·출시 판단	설계 동결, untouched final과 별도 사용자 적응 평가

부분 라벨과 API 계약

현재 배포 ML 경로는 5개 축 완성을 요구하고 일부 loader는 정수로 변환한다. v2.0은 축별 결측·다른 관찰 단위를 지원해야 한다. 점수 표시를 위해 결측을 50으로 채우는 방식으로 우회하지 않는다.

단계 4의 분석기 연구와 단계 5~6의 지정 상태 기반 연결 검증은 독립적으로 진행할 수 있다. 정확한 분석기가 완성될 때까지 모든 제품 연결 개발을 기다릴 필요는 없다.

DESIGN PROPOSAL v2.0

23 Gemini 유지와 모델링 담당 범위

현재 권고

Gemini를 유지하고 사용자 측정·상태 저장·응답 정책을 먼저 완성한다. 사용자가 변할 때마다 LLM 가중치를 재학습할 필요는 없다. 사용자 상태와 응답 지침을 바꿔 개인화할 수 있다.

방식	지금의 판단
프롬프트·상태 연결	우선 구현. 사용자 성향·선호·영어 수준을 검증 가능한 응답 지침으로 변환.
기존 LLM 파인튜닝	지침·예시만으로 해결되지 않는 반복 실패와 검수된 이상적 답변 데이터가 있을 때 검토.
LLM 처음부터 학습	현재 목표와 데이터 규모에서 우선 과제로 권하지 않음.

처음 모델링을 맡는 사람의 현실적인 산출물

- 공손성 한 축으로 데이터 정리 → 독립 채점 → baseline 비교 → 실패 사례 분석까지 완성한다.
- 입력/정답, train/dev/test, 누출, 기준 모델, MAE·일치도, 버전 재현성을 먼저 익힌다.
- 코드 구현은 도움을 받더라도 라벨 타당성·실험 공정성·결과 해석은 담당자가 이해한다.
- 그다음 상태 계산과 Gemini 제어 실험을 연결한다. 음성 모델과 LLM 파인튜닝을 동시에 시작하지 않는다.

학습 데이터의 목적이 다르다

발화 → 축 점수 데이터는 분석기 학습용이다. 대화 LLM을 튜닝하려면 대화 맥락·사용자 상태 → 검수된 적절한 답변 쌍이 필요하다. 자연 대화 corpus의 다음 발화가 그대로 최적의 영어 튜터 답변은 아니다.

DESIGN PROPOSAL v2.0

24 선행연구가 뒷받침하는 범위

연구	제공된 자료의 요약	Pally에서의 해석
Pepping et al. (2025)	스타일·외형 유사성의 주요 학습성과 효과가 유의하지 않았다고 보고.	유사성만으로 학습 향상을 보장하지 않음. 효과 없음의 확증도 아님.
Zhuo et al. (2026)	소규모 표본에서 성격 추천·주관적 학습 경험. 수업 중 고정 제어 신호.	정적 매칭을 동적 수렴의 검증으로 해석하지 않음.
Li et al. (2025)	학습 로그의 관찰 분석에서 상보성 관련 결과.	동적 적응의 인과 효과를 입증하지 않음.
Liew & Tan (2016)	상보 조건에서 정서·동기 이점, 학습 점수의 유의 효과는 확인되지 않았다는 요약.	편안함·호감과 학습 성과를 분리.
Tärning et al. (2019)	자기효능감·하위집단에 따라 단순 매칭의 결과가 달라짐.	하나의 동일한 반영 강도가 모든 사용자에게 최적이라는 가정 오류.

측정과 정책을 분리한다

분석기는 “어떻게 표현했는가”를 측정한다. 적응 정책은 “어떻게 답할 것인가”를 정한다. Pally가 닦아가는 경험은 제품 목표로 유지하되, 유사성·편안함·학습 성과를 따로 검증한다.

이 다섯 연구가 새 5축의 타당성, 0~100 앵커, 친숙도 감쇠식, 밌 사용률 구간을 검증한 것은 아니다. 새 기준의 수치와 운영 방법은 이 보고서의 설계 제안이다.

DESIGN PROPOSAL v2.0

25 실행 체크리스트와 최종 판단

체크	완료 판단
정의	5개 제품 지표 중 4개 행동 측정과 1개 관계 계산이 구분됐는가
데이터	원문·전사·음성·맥락·화자·corpus 버전이 추적되는가
라벨	인간/LLM/rule과 원래 채점 조건·독립성·수정 이력이 보존되는가
기준	80~120 anchor에서 해석 불일치를 점검했는가
결측	음성 없음·탐색 기회 없음이 0점이나 50점으로 바뀌지 않는가
평가	human dev와 untouched final이 분리됐는가
제품 연결	분석 결과가 실제 Gemini 지침·TTS 설정에 반영됐는가
학습 지원	영어 수준·속도·교정 선호가 성격과 분리됐는가
적응	사용자 선호 우선·변화 상한·시스템 유도 행동 구분이 있는가
효과	뒹뒹했다는 느낌과 학습 성과를 별도 평가했는가

개발의 출발점

우선 새 스키마로 작은 anchor를 만들고, 공손성 분석 실험과 지정 상태 기반 Gemini 제어 실험을 완성한다. 이후 표현성·ميم·탐색·친숙도를 각자 맞는 데이터와 계산 방식으로 연결한다.

새 축 정의는 데이터가 수집 가능하고 출력에 연결 가능한지를 기준으로 선정했다. 모든 축을 심리 성격으로 포장하거나 모든 corpus에 5개 숫자를 억지로 채우는 방식은 채택하지 않는다.

DESIGN PROPOSAL v2.0

26 근거 목록: 코드와 프로젝트 자료

- [C1] 분석기 선택·context 처리: ai/analyzers.py
- [C2] 학습 스키마·기본 데이터·정수 변환: ai/ml_baseline.py
- [C3] STT·Gemini·TTS·메시지 저장: backend/main.py
- [C4] 누적·캐릭터 계산: ai/matrix_engine.py
- [C5] 데이터 통합과 provenance 필드: build_real_speech_axis_dataset.py
- [C6] corpus 상태·후보·권한 기록: real_speech_corpus_manifest.json
- [C7] 기존 ML 전환·검수 계약: docs/ml-transition-contract.md
- [C8] Ridge-teacher 대조 실험: experiment_b1plus_linear_student.py
- [C9] 고정 어휘 목록 처리: ai/reddit_vocabulary.py
- [C10] 이전·다음 발화 구성: scripts/conversation_context.py

직접 대조한 데이터

axis_dataset_week2.jsonl / axis_dataset_combined_real_speech_experimental.jsonl / ml_transition_train_purged_2940.jsonl / ml_transition_gold_human_200.jsonl / ml_transition_train_candidates_1200.jsonl 및 NICT·AMI·CHiME·Taskmaster 추출 JSONL.

사용자 제공 자료

- [U] 본 대화의 제품 정의와 정정 사항.
- [R] “Adaptive AI와 학습자-에이전트 유사성: 개인화가 항상 최적의 학습환경을 제공하는가?” 선행연구 5편 요약.
- [D0] 기존 실제 발화 데이터셋 조사 자료.

이전 산출물: Pally 5축 커뮤니케이션 스타일 데이터 라벨링 기준 보고서 v1.0, 2026-09-16.

v1.0 대비 수정

Intimacy를 발화 친밀감에서 사용 이력 기반 친숙도로, Humor를 일반 유머에서 밈·유행어 사용으로 변경했다. Energy는 말속도와 분리한 음성 표현성으로 좁혔다. 데이터 출처와 라벨 출처를 별도 차원으로 명시했다.

DESIGN PROPOSAL v2.0

27 근거 목록: 데이터와 모델 적응

[D1] otoSpeech full-duplex 280h: 공식 데이터 카드

[D2] otoSpeech Task 20h: 공식 데이터 카드

[D3] ICSI 대화행위 분석: SRI 연구 논문

[D4] DiPCo: 저자·배포 데이터 기록

[D5] MSP-Conversation: 연구실 공식 소개·접근 안내

[D6] Open Yap: 공식 데이터 카드·전체 자료 접근 안내

[D7] Google Cloud: 모델 적응·파인튜닝 안내

확인한 것과 확인하지 않은 것

- 공개 카드의 자료 구성·접근 안내와 저장소의 실제 필드를 확인했다. 신규 corpus 전체를 다운로드·감사·라벨링한 것은 아니다.
- otoSpeech에는 다른 가공 버전도 존재한다. 본문은 raw 280h와 Task 버전을 구분하며, 모든 버전의 전사·품질이 같다고 가정하지 않는다.
- Open Yap 전체 이용 계약과 공개 샘플 라이선스를 혼동하지 않는다. MSP의 학술 접근 안내는 제품 배포 허가를 자동 의미하지 않는다.
- ICSI의 모든 원본·주석에 동일 라이선스가 적용된다고 단정하지 않는다. 데이터 이용에 대한 최종 법률 검토를 대신하는 보고서가 아니다.
- 새 5축 Rubric·수치 기준·정책 효과는 검증 전 제안이다. 독립 채점과 분리된 최종 평가 전에는 인간의 스타일 지각 학습을 입증했다고 결론내리지 않는다.